

Paper Summaries

Generated: 2026-07-23 16:09

This report contains structured paper summaries, not full-paper translations.

1. A survey on large language model based autonomous agents

Basic Info

- year: 2024
- venue: Frontiers of Computer Science
- links: - <https://link.springer.com/article/10.1007/s11704-024-40231-1>
- <https://arxiv.org/abs/2308.11432>
- tags: - survey
- classic

What / Why

这篇综述解决的是“LLM-based autonomous agents（基于大语言模型的自主智能体）到底由哪些模块组成、能做什么、怎么评估”的入门问题。传统 autonomous agent 研究常在受限环境里训练策略，而 LLM 让 agent 可以通过自然语言理解、推理、规划、记忆和工具使用进入更开放的任务环境。对新手来说，这篇论文的价值在于给出全景地图：先理解 agent architecture（智能体架构），再看 application（应用），最后看 evaluation（评估）。

Method

论文不是提出新算法，而是做系统综述。它把 LLM agent 架构拆成 profiling module（角色画像模块）、memory module（记忆模块）、planning module（规划模块）和 action module（行动模块）。其中 memory 又区分短期记忆、长期记忆和 hybrid memory（混合记忆）；planning 讨论单路径推理、多路径推理、外部 planner、反馈驱动修正；action 则包括工具使用、代码执行、API 调用和环境交互。

Innovation

主要贡献是提出一个统一分类框架，把分散的 LLM agent 工作放到 construction-application-evaluation 三条线里。它把 memory、planning、action 这些概念和具体论文对应起来，对找研究方向特别有用。相对只讲 prompting 或只讲工具调用的综述，它更像“总目录”。

Experiments

作为 survey，没有自建实验。它整理了已有工作中的应用和评估方式。评估部分区分 subjective evaluation（主观评估）和 objective evaluation（客观评估），并指出 objective evaluation 需要同时考虑 metrics（指标）、protocols（协议）和 benchmarks（基准）。常见指标包括 task success（任务成功）、efficiency（效率）、human preference（人类偏好）、social/emotional behavior（社会与情感表现）等。

Reliability And Limits

证据强度适合作为入门综述和 related work 框架，但不适合作为某个具体 benchmark 的最新结论。论文覆盖到 2024 年，后续的 agent safety、MCP tool use、long-term memory benchmark 等方向需要补新文献。另一个局限是很多分类仍偏概念层，缺少统一实证比较。

Reading Guide

先读 Section 2 的 architecture design，尤其是 profiling/memory/planning/action；再读 Fig. 5 和 Section 4 的 evaluation；最后看 challenges/future directions。对你找方向最有用的是 memory、planning with feedback、objective evaluation 这几块。

2. From language to action: a review of large language models as autonomous agents and tool users

Basic Info

- year: 2026
- venue: Artificial Intelligence Review
- links: - <https://link.springer.com/article/10.1007/s10462-025-11471-9>
- <https://link.springer.com/content/pdf/10.1007/s10462-025-11471-9.pdf>
- tags: - survey
- tool use
- multi-agent

What / Why

这篇综述关注的是 LLM 如何从 language model (语言模型) 变成 action-capable agent (能行动的智能体)。问题核心是: LLM 不只是生成文本, 还要解释指令、拆解连续任务、调用工具、接受反馈、在单智能体或多智能体系统里完成真实任务。它试图回答 2023-2025 年高质量会议/期刊里 LLM agent 的架构、认知机制、工具集成、benchmark 和未来方向。

Method

论文采用系统综述方式, 筛选 2023-2025 年 A*/A-ranked conferences 和 Q1 journals 的论文, 并围绕 7 个 research questions 组织内容。它分析 single-agent 与 multi-agent systems (单/多智能体系统)、external tools (外部工具)、reasoning (推理)、planning (规划)、memory (记忆)、prompting/fine-tuning (提示与微调) 以及 benchmarks and assessment protocols (基准与评估协议)。

Innovation

它的价值在于把 autonomous agents 和 tool users 放在同一条主线里看: 从自然语言理解到工具调用, 再到反馈驱动连续行动。它还整理了 68 个公开数据集, 用来评估不同任务上的 LLM-based agents。对你找研究方向来说, 它比单篇方法论文更适合定位“哪些方向已经拥挤, 哪些问题仍未解决”。

Experiments

作为 review, 没有新实验。页面摘要显示它分析了 68 个公开数据集, 并讨论当前 benchmarks、assessment protocols、verifiable reasoning (可验证推理)、self-improvement (自我改进) 和 personalization (个性化)。由于 PDF 下载超时, 本总结基于 Springer HTML 元数据和摘要, 细节置信度低于已下载正文的 4 篇。

Reliability And Limits

优点是时间新、覆盖面广, 且明确面向 tool users。局限是目前只核对到 HTML 摘要, 没有完整 PDF 文本, 因此不能确认其 7 个 research questions 和 10 个 future directions 的逐项细节。正式引用或写综述前建议重新下载 PDF 或通过学校网络访问。

Reading Guide

先读 abstract 和 introduction, 确认它的 7 个 research questions; 然后读 benchmark/dataset section, 看 68 个数据集如何分类; 最后读 future directions, 用来和 SafeAgentBench、AMP、tool-learning survey 交叉定位研究空白。

3. SafeAgentBench: A Benchmark for Safe Task Planning of Embodied LLM Agents

Basic Info

- year: 2024
- venue: arXiv / benchmark paper
- links: - <https://arxiv.org/abs/2412.13178>
- <https://github.com/shengyin1224/SafeAgentBench>
- <https://huggingface.co/datasets/safeagentbench/SafeAgentBench>
- tags: - benchmark
- replication-friendly
- safety

What / Why

这篇论文解决的是 embodied LLM agents（具身大模型智能体）在执行任务时是否具有 safety awareness（安全意识）的问题。已有 embodied planning benchmark 多关注能不能完成任务，却较少测试 agent 面对危险指令时是否会拒绝、规避或安全失败。作者认为，如果 agent 能很好地规划，也可能更高效地执行危险任务，因此需要专门评估安全规划。

Method

论文提出 SafeAgentBench，由三部分组成：750 个可执行任务的数据集、SafeAgentEnv 具身环境、以及 execution-based 和 semantic LLM-based 两种评估方法。任务覆盖 10 类潜在危险、3 种任务类型：detailed tasks（详细任务）、abstract tasks（抽象任务）和 long-horizon tasks（长程任务）。环境基于 AI2-THOR 和低层控制器，支持 17 个 high-level actions 和多智能体执行。

Innovation

创新点在于把 agent safety 从静态文本判断推进到 interactive simulation（交互式仿真）里的可执行任务规划。它同时覆盖 explicit hazards（显式危险）和 implicit hazards（隐式危险），并引入 safe control tasks 对照。相比只看任务成功率的 benchmark，它把拒绝危险任务、避免风险执行、长程安全完成都纳入评价。

Experiments

数据集包含 750 个任务，其中 450 个有安全风险，300 个为对应安全任务。实验评估 9 个代表性 embodied LLM agent baseline，并用 GPT-4、Gemini-2.5-pro、Llama3-8B、Qwen2-7B、DeepSeek-V2.5 等模型比较。指标包括 rejection rate（拒绝率）、risk/success rate（风险/成功率）、execution rate（执行率）、usage time（耗时），长程任务还看 completed-and-safe、completed-but-unsafe、incomplete。关键结果：最安全的 baseline 在 detailed hazardous tasks 上也只有 10% 拒绝率，abstract hazardous tasks 上 ReAct 最高约 32%；长程任务中 ProgPrompt/相关基线有 50%-70% 安全完成区间；换更强 LLM 并不能显著提升安全意识，agent 架构影响更大。

Reliability And Limits

证据强度较高，因为有数据集、环境、代码和多 baseline。局限是任务生成使用 GPT-4，再经过筛选和人工审核，仍可能带有生成偏差；环境是仿真环境，和真实机器人部署有差距；LLM-as-judge 虽有人类一致性验证，仍可能受模型偏差影响。

Reading Guide

先读 abstract 和 Fig. 1; 然后读 Section 3 dataset composition; 再读 Section 4 evaluation metrics; 最后重点看 Table 2、Fig. 4、Fig. 5 和 Section 5.6。若你想做 agent safety/evaluation, 这篇最值得复现。

4. Agent-Memory Protocol: A Privacy-Focused Protocol for LLM Agents and User Memory Interaction

Basic Info

- year: 2026
- venue: PMLR
- links: - <https://proceedings.mlr.press/v317/wu26a.html>
- <https://raw.githubusercontent.com/mlresearch/v317/main/assets/wu26a/wu26a.pdf>
- tags: - memory
- safety
- privacy
- replication-friendly

What / Why

这篇论文解决的是 long-term memory (长期记忆) 和 privacy (隐私) 之间的冲突。LLM agent 要跨会话记住用户偏好、历史行为和上下文, 但如果直接把原始记忆放进 prompt、检索结果或日志, 就会把个人身份信息 (PII) 暴露给外部模型或第三方基础设施。论文目标是让 agent 能使用长期记忆, 同时保证敏感标识符不越过用户信任边界。

Method

作者提出 Agent-Memory Protocol (AMP), 核心是三个确定性操作: APPEND / PACK / HYDRATE。APPEND 在写入记忆时做 redact at rest (静态脱敏), 把姓名、邮箱、日期、账号等替换成稳定 placeholder; PACK 按当前任务构造 token-budgeted redacted memory pack (任务相关脱敏记忆包); HYDRATE 在模型输出后, 只在本地 trusted endpoint 上把 placeholder 还原为真实实体。传输层使用 JSON over mTLS/local socket, 消息带 timestamp、nonce、Ed25519 signature, 以支持鉴权、防重放和审计。

Innovation

创新点是把隐私保护从基础设施层提升到 language-level protocol (语言层协议)。传统 memory/RAG 方法关注检索质量和 token 效率, 但常把明文记忆送进模型。AMP 用 redaction-hydration boundary (脱敏-还原边界) 把“模型推理所需语义”和“用户身份信息”解耦, 并允许与 MCP、A2A 这类 agent/tool 协议组合。

Experiments

论文主要是协议设计和 case study, 不是大规模 benchmark。它展示了医疗场景 radiology rescheduling 和金融场景 portfolio transfer/tax planning。实现细节显示 PACK 使用 Sentence-BERT over redacted text, pack construction 在 Apple M2 CPU 上小于 50ms, hydration 小于 10ms, placeholder 增加约 7.3% 存储开销。没有看到与 MemGPT、LangMem、Zep 等系统的系统性准确率对比。

Reliability And Limits

这是强设计论文, 但实证证据有限。协议合理、可实现、问题重要, 但还需要更大规模实验验证: 脱敏是否降低任务成功率、NER 错漏如何影响隐私、placeholder 是否被模型错误改写、多 agent 场景下权限如何组合。适合做后续研究, 而不是直接当作已充分验证的最终方案。

Reading Guide

先读 abstract 和 Problem Setting; 然后读 AMP 的 APPEND/PACK/HYDRATE; 再读 transport handshake; 最后读两个 case studies。若你想做 memory + privacy, 这篇可以作为研究起点: 补 benchmark、补攻击测试、补效用-隐私权衡实验。

5. LLM-Based Agents for Tool Learning: A Survey

Basic Info

- year: 2025
- venue: Data Science and Engineering
- links: - <https://link.springer.com/article/10.1007/s41019-025-00296-9>
- <https://link.springer.com/content/pdf/10.1007/s41019-025-00296-9.pdf>
- tags: - survey
- tool use
- benchmark

What / Why

这篇综述解决的是 LLM-based agents 如何学习和使用工具的问题。LLM 本身受训练数据、幻觉和实时能力限制，很多真实任务需要 API、搜索、代码执行、多模态模型或外部数据库。论文把 tool learning（工具学习）定义为 agent 判断是否需要工具、检索哪个工具、如何调用工具并利用反馈完成任务的能力。

Method

论文系统整理 tool-learning agent 的典型架构和三类核心子任务：tool invocation（是否调用工具）、tool retrieval（检索合适工具）、tool planning/usage（规划工具调用顺序和参数）。它区分 training-based 和 non-training-based 工具检索方法，讨论依赖模型自身推理或外部 reasoning tools 的规划方式，并扩展到 multimodal tools（多模态工具）。

Innovation

主要贡献是把工具学习从零散的 API 调用论文整理成一个任务框架：When/Which/How，也就是何时用工具、用哪个工具、怎么用。它还把 benchmark、指标、应用场景和安全伦理问题放在一起，适合用来定位 tool-use agent 的研究空白。

Experiments

作为 survey，没有新实验。它整理了大量工具学习 benchmark 和指标。文中列出 API-Bank、APIBench、ToolBench、ToolQA、ToolAlpaca、RestBench、TOOLE、StableToolBench、ToolEyes、InjectAgent、Noisy-ToolBench 等。例子包括 ToolBench/RapidAPI 约 16k APIs，ToolAlpaca 约 400 APIs 和 3938 tool-use instances，InjectAgent 覆盖 17 个用户工具和 62 个攻击工具、1054 个测试样例。指标包括 tool invocation accuracy、tool retrieval accuracy、parameter correctness、task success、robustness/security、manual assessment 和 LLM-based assessment。

Reliability And Limits

综述覆盖面很强，但它本身不验证某个新方法。工具学习领域 benchmark 很碎片化，真实 API 会变化，虚拟 API 又可能损失现实性。因此读这篇时要注意：它给的是 map，不是最终标准答案。对研究来说，稳定可复现的 tool-use evaluation 仍然是机会。

Reading Guide

先读 abstract 和 Section 2 的 task definition，记住 Three Ws；再读 Section 3/4 的 tool retrieval 和 tool planning；重点读 Section 7 的 benchmarks 和 metrics；最后读 safety/ethics 部分。若你想做 tool-use safety/evaluation，这篇和 SafeAgentBench 应该一起读。