

Agent 领域选题形成包

从领域地图到可证伪的最小实验

交付目的：提供可追溯的候选与论证，供导师讨论、质疑和进一步收敛；不声称已经确定可投稿选题。

证据纪律：正式论文、预印本和跨论文推测分开标记；每项关键事实附论文或官方入口；“本人选择”保留待本人填写。

本轮交付回答什么问题

不是“收集了多少篇”，而是先建立可讨论的问题结构。

中心判断：现有 Agent

工作正从“能否完成任务”转向“在动态环境中如何训练、评测、复用经验并保持安全”。

- 宽检索池：170 条去重元数据，覆盖后训练、记忆、工具/计算机操作、评测与安全。
- 核心证据集：12 篇正式会议锚点 + 12 篇近期前沿信号；前沿信号不与正式论文等权。
- 产出包括：方向地图、缺口清单、三个候选问题、实验资源入口和待确认的研究决策记录。
- 当前没有提交任何计费 GPU 作业，因此没有伪造基线实验结果。

来源：CCF 第七版目录与 Full/Regular 口径：https://www.ccf.org.cn/Academic_Evaluation/By_category/

领域地图：七条问题线 + 一个成本维度

问题线	科学问题	优先任务环境与中文指标
能力获取与智能体后训练	如何把多轮工具交互、用户澄清和环境反馈转化为稳定且可验证的后训练信号。	任务成功率、工具调用正确率、奖励稳定性、训练吞吐、调用成本。
长程决策、探索与信用分配	如何把长程任务的最终成败公平分给规划、关键状态和具体工具动作。	任务成功率、关键步骤正确率、样本效率、训练稳定性、轮次或工具预算。
记忆、经验复用与个性化适应	如何让智能体从连续交互中保留、压缩、检索和更新可迁移经验，同时避免遗忘、冲突和隐私泄露。	后续任务成功率、经验复用率、遗忘或负迁移、检索延迟、存储与令牌开销。
工具使用、计算机操作与具身交互	如何在动态工具、网页与图形界面中可靠规划、执行和适应。	端到端任务成功率、工具调用正确率、执行时间、令牌消耗、调用成本、安全完成率。
多智能体协作、冲突与治理	如何分配角色、共享状态、协调冲突并对多智能体过程进行治理和审计。	协作成功率、规划准确率、延迟、通信成本、攻击成功率、审计覆盖率。
评测、泛化与可复现性	如何评价智能体过程能力、跨环境泛化、反思质量和可复现实验条件，而非只看单一终局分数。	任务成功率、过程正确性、失败避免率、泛化差距、复现成功率、成本。
安全、可靠性与失效控制	如何在恶意内容、权限边界、风险任务和用户转递内容下维持可控、安全的智能体行为。	攻击成功率、拒绝率、安全完成率、隐私泄露率、误拒绝率、额外延迟。

跨方向维度：效率和资源成本，包括训练吞吐、端到端延迟、令牌消耗、工具调用成本、显存和卡时。

注：跨论文的“主要争议”和“证据不足”均为推测，不能替代原文复核。

正式锚点把问题线落到可复现实验环境

问题线	代表锚点	可观察失败 / 已知指标
工具与网页	WebArena、OSWorld	网页跨站操作与桌面状态依赖。WebArena 官方页：GPT-4 智能体 14.41%，人类 78.24%。
工具学习	Toolformer、ToolLLM	何时调用、如何填参数、怎样整合返回结果；ToolLLM 覆盖 16,464 个 API、49 类。
评测	AgentBench、GAIA、SWE-bench、 τ -bench	跨环境比较、可验证补丁和多轮服务交互；SWE-bench 初始最佳 Claude 2 为 1.96%。
具身规划	零样本规划、ReAct、WebShop	文本知识无法自动变成稳定执行；ReAct 在 ALFWorld、WebShop 报告成功率绝对提升。

来源：官方会议页：ICLR 2024 AgentBench、ToolLLM、GAIA、SWE-bench、WebArena；NeurIPS 2023 Toolformer；OpenReview τ -bench；各入口见论文证据卡。

证据不是同一层级：先用锚点定边界，再用前沿信号找缺口

层级	本轮数量	可用方式	不能做的推断
正式会议锚点	12	定义问题、环境、公开指标与基线	不能跨模型、不同环境直接比较优劣
近期前沿信号	12	发现信用分配、记忆与安全的新命题	不能当作已验证结论或 CCF-A 论文
跨论文综合	3 项缺口	形成可证伪候选	必须标为推测，需用同环境对照验证

当前严格保留 12 个正式锚点，而不是用质量较弱材料凑成 18 个“CCF-A”。余下正式发表状态会继续核验。

缺口清单：不是结论，而是最小可验证的争议

动态工具环境中的步骤级信用分配仍缺少跨环境证据

状态：局部解决；置信度：中；性质：推测

多项工作已把奖励拆到清单、状态图、事后评估或层级子目标，但它们主要在各自环境报告提升；尚缺在工具变化、用户澄清和成本约束同时存在时的可比证据。

最低成本验证：在同一工具环境、同一模型和相同轮次预算下，对比轨迹级、步骤级与状态条件化信用分配。

经验或记忆的正确性与真实界面执行成功之间存在未充分解释的落差

状态：局部解决；置信度：中；性质：推测

已有持久记忆、程序记忆和知识演化方法报告效率或知识质量提升，但 UI-Evol 等记录显示知识正确并不必然带来操作成功；因果机制和失败边界尚不清楚。

最低成本验证：把记忆质量、检索命中、计划一致性和界面执行分开测量，并检查记忆更新对不同任务长度的影响。

安全评测对用户转递内容、工具权限和正常任务完成之间的联合权衡证据不足

状态：证据不足；置信度：低；性质：推测

安全基准、默认护栏与提示注入研究分别覆盖风险任务、权限边界或攻击路径，但现有记录不足以证明同一方案能同时降低用户转递攻击并保持正常多步工具任务完成。

最低成本验证：在同一工具任务上设置正常、外部注入和用户转递注入三类条件，同时报告成功率、攻击成功率、误拒绝率和额外成本。

来源：支持/反证论文链接见：选题形成/缺口清单.md 与 论文证据卡.json。

三个候选方向：价值、证据、可证伪性与资源适配度同时比较

候选	问题	分数：重要性 / 证据 / 创新 / 可证伪	风险
1. 面向动态工具任务的状态条件化步骤级信用分配	现有长程工具强化学习难以区分失败轨迹中的有效步骤与真正造成失败的步骤，且工具或用户状态变化会破坏简单的轨迹级比较。	5 / 4 / 4 / 5	奖励构造可能泄漏答案；状态等价关系可能过粗或过细；跨环境实现成本高。
2. 将界面执行反馈转化为可验证程序记忆的经验复用	正确的界面知识或检索记忆不一定转化为成功执行，线性记忆还会产生冲突和过期经验。	4 / 3 / 4 / 4	GUI 环境不稳定；状态表示与隐私数据处理复杂；可能被简单长上下文基线击败。
3. 面向用户转递内容的最小权限工具智能体安全评测与控制	工具智能体可能通过用户转递文本接收恶意指令；只测攻击阻断或只测任务完成都无法说明真实可用性。	5 / 2 / 4 / 5	安全实验设计与数据授权要求高；攻击集合可能快速过时；导师需要审查边界。

推荐顺序是 Codex 的暂定建议，不是代替本人或导师的决定。

首选方向提案

1/2：把长程失败归因到关键状态与工具动作

面向动态工具任务的状态条件化步骤级信用分配

研究问题：现有长程工具强化学习难以区分失败轨迹中的有效步骤与真正造成失败的步骤，且工具或用户状态变化会破坏简单的轨迹级比较。

可证伪假设：若在同一可观察状态下比较候选工具动作，并把关键状态变化与最终验证信号结合，长程任务可在相同预算下提升成功率且减少无效调用。

替代解释：提升可能来自更强模型、更多采样或任务特定奖励工程，而非信用分配本身。

为何暂排第一：相较安全方向，当前可验证终局信号更容易获得；相较记忆方向，干预变量更清晰。

研究角色：不是宣称新奖励必然更好，而是检验“状态条件化”是否在相同模型、任务和调用预算下产生独立贡献。

来源：前沿支撑：CM2、迭代奖励校准、图式信用分配、事后信用分配、HiPER、Memory-R2；均在论文证据卡中保留其原始入口。

首选方向提案 2/2：最小实验与证伪边界

要素	具体设计
环境	优先选择 ALFWorld 或一个公开、可记录逐步状态的工具环境；先以 30-100 个分层样例覆盖至少三类任务。
比较组	相同模型和调用预算：轨迹级奖励、清单式步骤奖励、状态条件化奖励。
中文指标	任务成功率、步骤级正确率、工具调用次数、平均轮次、调用成本、训练稳定性。
记录	总体指标、逐样例结果、五个代表性失败案例、固定代码提交/环境/随机种子。
证伪条件	若在相同预算和同一环境下既无成功率提升、也不能减少无效调用，或收益完全由更大采样量解释，则该假设不成立。
风险控制	避免奖励泄漏；先用小规模、可验证终局任务；不把单次运行写成统计充分结论。

来源：资源入口：[datasets/数据集总览.md](#)；ALFWorld、Search-R1、BFCL、STeCa 等均有下载或项目页。

实验资源不是选题价值的替代品，但决定最小实验能否落地

候选	优先资源	测试能力	获取方式与边界
信用分配	ALFWorld、Search-R1、BFCL、STeCa	多步规划、工具调用、逐步日志	公开项目或数据入口；版本、许可、大小不明时只登记。
验证型记忆	EvoMemBench、OSWorld、TravelPlanner	经验复用、环境变化、执行成功	环境较重，需先核验部署与许可证。
安全权限	SafeRAG、SafeAgentBench、OS-Harm	攻击成功率、正常任务成功率、误拒绝	仅采用授权的无害安全评测环境；导师需审查边界。

实验资源总览已把 39 条机器版本记录合并为 37 个阅读入口；原始版本化账本仍保留在 `datasets/index/datasets.json`。

服务器基线验证：已确认可用，但尚未提交计费作业

- 账号环境的项目可写目录统一使用 \$HOME/run，对应 /data/run01/scxk701；禁止使用系统 /run。
- 个人主目录仅 1 GiB，不用于数据、模型或实验产物；\$HOME/run 已验证可写，配额为 300 GiB。
- 可见队列包括 gpu_4090、gpu_5090、hp_4090；当前普通队列价格、可用时限和赠送额度抵扣规则未得到书面确认。
- 因此尚未提交 sbatch、交互 GPU 或任何可能产生费用的作业。

下一步提交前必须向本人展示：队列、卡数、最长运行时限、预计最大费用与实验命令；只有收到明确确认后才提交。

请导师帮助判断的四个问题

问题	希望得到的判断
研究价值	“状态条件化步骤级信用分配” 是否足够重要，还是更应收敛到某类特定工具/用户交互任务？
实验定位	优先以 ALFWorld/工具环境做机制验证，还是直接投入更真实但更重的 WebArena、OSWorld？
基线选择	哪些公开强基线与模型规模更符合课题组资源和公平比较要求？
安全边界	安全候选是否应并行探索，还是先作为后续扩展以避免研究面过宽？

建议的当前动作：先跑通一个可审计小基线，确认失败模式，再决定是否把首选方向立项。

本人选择与一行理由保留在：交付包/研究决策记录.md。

附录：核心正式锚点与官方入口

论文	正式来源	用于回答的问题
Language Models as Zero-Shot Planners: Extracting Actionable Knowledge for Embodied Agents	正式 ICML 2022 Conference	工具使用、计算机操作与具身交互
ReAct: Synergizing Reasoning and Acting in Language Models	正式 ICLR 2023 Conference	工具使用、计算机操作与具身交互、长程决策、探索与信用分配
Toolformer: Language Models Can Teach Themselves to Use Tools	正式 NeurIPS 2023 Conference	能力获取与智能体后训练、工具使用、计算机操作与具身交互
WebShop: Towards Scalable Real-World Web Interaction with Grounded Language Agents	正式 NeurIPS 2022 Conference	工具使用、计算机操作与具身交互、评测、泛化与可复现性
AgentBench: Evaluating LLMs as Agents	正式 ICLR 2024 Conference	评测、泛化与可复现性、工具使用、计算机操作与具身交互
ToolLLM: Facilitating Large Language Models to Master 16000+ Real-World APIs	正式 ICLR 2024 Conference	能力获取与智能体后训练、工具使用、计算机操作与具身交互、评测、泛化与可复现性
GAIA: a benchmark for General AI Assistants	正式 ICLR 2024 Conference	评测、泛化与可复现性、工具使用、计算机操作与具身交互
SWE-bench: Can Language Models Resolve Real-world GitHub Issues?	正式 ICLR 2024 Conference	评测、泛化与可复现性、工具使用、计算机操作与具身交互
WebArena: A Realistic Web Environment for Building Autonomous Agents	正式 ICLR 2024 Conference	工具使用、计算机操作与具身交互、评测、泛化与可复现性
AppWorld: A Controllable World of Apps and People for Benchmarking Interactive Coding Agents	正式 ACL 2024 Long Paper Conference	工具使用、计算机操作与具身交互、评测、泛化与可复现性
OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments	正式 NeurIPS 2024 Conference	工具使用、计算机操作与具身交互、评测、泛化与可复现性
τ -bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains	正式 ICLR 2025 Conference	评测、泛化与可复现性、工具使用、计算机操作与具身交互、安全、可靠性与失效控制

每篇的论文页、PDF 与 CCF 目录入口均在选题形成/保留证据集.json 和 论文证据卡.json 中。